

2^n 元数神经网络模型:多值图象的识别应用^①

帅建伟 陈振湘 刘瑞堂 吴伯僖

(物理学系)

摘要 对 2^n 元数神经网络模型的计算机数值模拟结果表明,其存贮容量和纠错能力随 n 的增大而降低,讨论了四态复数模型或十六态四元数模型的四态或十六态多值图象的识别应用实例,并对其光学实现进行了初步的探讨.

关键词 神经网络, 2^n 元数, 图象识别

中国图书分类号 O 411.3

随着计算机的普及化,计算机图象成为一个越来越重要要的学科分支,16, 256级灰度和彩色图象在计算机中被广泛的使用.但由于计算机的串行处理系统和串行读写系统,并不能很好地完成高精度图象的高速处理功能.而人脑能大量存贮图象,对图象能快速存取和快速处理,因此一个重要的问题是能否智能化地处理图象:如分布式存贮,并行处理,联想识别等.由此形成了近年来的一个神经网络的研究热潮.为处理多值图象,人们提出了各种多值神经网络模型^[1~4].

我们提出了 2^n 元数神经网络模型^[5],该模型具有以下优点:为双态模型,可用现在成熟的集成电路实现;其图象编码方式与计算机图象编码一一对映;其存贮容量比与Hopfield神经网络模型相同,且不随 n 而变.本文对 2^n 元数神经网络模型的存贮容量和纠错能力进行了进一步的数值模拟研究,并把该模型应用于多值灰度或彩色图象的识别中.第四节简要讨论了模型的光学实现可能性.

1 网络存贮容量和纠错能力的计算机数值模拟

文献[5]用计算机数值模拟统计了对不同的 N ,存贮图象正确回忆率大于90%时的最大 $M-N$ 统计曲线,得到下述结论: 2^n 元数模型四种网络($n=0,1,2,3$)的存贮容量比与 n 的取值无关,但存贮容量随 n 增大略有降低.

下面从另一个角度来说明上述离散 2^n 元数神经网络模型的存贮容量.设网络中有 $N=200$ 个神经元,多次随机产生 M 个存贮图象 T^n ,把存贮图象作为输入,统计其正确回忆率随 M 变化的统计曲线,如图1.由图知四模型的统计曲线具有相似的形状,所以同样可得到上述结论.

对于离散 2^n 元数神经网络模型,为表征输入图象 T 与存储样本 T^n 的差别大小,须先定义一个距离函数

^① 本文1994-09-29收到; 国家自然科学基金重点资助项目

$$D = \sum_{i=1}^{2^n} \sum_{m=1}^N |a_{im}^v - a_{im}| \quad (1)$$

这里 a_{im}^v 和 a_{im} 分别表示存储样本 T^v 和输入图象 T 的第 m 个分量(也即是一 2^n 元数)的第 i 个部分, 其中 $0 < i \leq 2^n$, $0 < m \leq N$. 该距离也即是广义的 2^n 元数汉明距离. 若图象 T 与存储样本 T^v 的 2^n 元数汉明距离为 D , 则表示图象 T 相对于存储样本 T^v 具有 $\gamma = D/2^n N$ 的噪声.

图 2 画出了当网络存贮 $M=5$ 个图象, 加噪图象的收敛百分比 δ 为 80% 时的随机噪声 γ 与神经元个数 N 的统计关系曲线. 图 3 画出了当神经元数 $N=100$, 存贮图象数 $M=5$ 时, 加噪图象的收敛百分比 δ 与随机噪声 γ 的统计关系曲线. 由图可知, 复数神经网络模型和四元数神经网络模型的纠错能力相差不大, 但约低于 Hopfield 模型而又高于八元数神经网络模型. 我们可以定性理解该结论: 由于多元数基矢间对乘法具有轮换关系, 且随 n 增加, 轮换变大. 这实际上构成了一种交叉干扰, 从而造成了随 n 增加, 纠错能力变小.




图 2 2^n 元数网络中 $M=5$ 加噪图象的收敛百分比为 80% 时的随机噪声 γ 与 N 的统计曲线

Fig. 2 The curves of the random noise via the neuron number N of the models with $M=5$ and correct recognition percent 80%




图 1 2^n 元数模型中 $N=200$, 存贮图象的正确回忆率随 M 变化的统计曲线

Fig. 1 The curves of the correct retrieval percent via the storage patterns number of the models with $N=200$




图 3 2^n 元数网络中 $N=100$, $M=5$ 时, 加噪图象的收敛百分比 δ 与随机噪声 γ 的统计曲线

Fig. 3 The curves of the correct recognition percent via the random noise of the models with $N=100$ and $M=5$

2 2^n 元数神经网络模型的应用

我们认为复数神经网络模型可应用于四值灰度或彩色图象的识别中. 四元数神经网络模

型可应用于 16 值彩色或灰度图象的识别中. 八元神经网络模型可应用于 256 值彩色或灰度图象的高分辨率识别中. 对于 4, 16 和 256 值彩色或灰度图象的识别, 其编码方式可与计算机图象的二进制编码方式相同. 如在表 1 中, 我们列出了 16 种颜色的计算机编码和四元数神经元编码:

表 1 由三基色构成十六色的计算机编码和四元数神经元编码
Tab.1 The sixteen-color codes of the computer and the Hamilton neuron

颜色	计算机	神经元	颜色	计算机	神经元
0 黑	0000	$(-1-i-j-k)$	8 深灰	1000	$(+1-i-j-k)$
1 兰	0001	$(-1-i-j+k)$	9 淡兰	1001	$(+1-i-j+k)$
2 绿	0010	$(-1-i+j-k)$	10 淡绿	1010	$(+1-i+j-k)$
3 青	0011	$(-1-i+j+k)$	11 淡青	1011	$(+1-i+j+k)$
4 红	0100	$(-1+i-j-k)$	12 淡红	1100	$(+1+i-j-k)$
5 紫	0101	$(-1+i-j+k)$	13 淡洋红	1101	$(+1+i-j+k)$
6 棕	0110	$(-1+i+j-k)$	14 黄	1110	$(+1+i+j-k)$
7 淡灰	0111	$(-1+i+j+k)$	15 白	1111	$(+1+i+j+k)$

我们对复数离散神经网络模型的四值图象识别进行了初步的计算机模拟, 如对 7×10 点阵英文字母 A 的识别: 网络中存贮有三种字母 A, 模拟表明, 这三种不同灰度或颜色的 A 均为网络的稳定存贮图象. 而若输入一些其汉明距离达 20bit (近 15% 噪声) 的稍有变形的字母 A, 模型正确识别率约为 99%. 若输入一些其汉明距离达 40bit (近 30% 噪声) 的变形字母 A, 正确识别率为 66%. 图 4(a) 为存贮字母, (b) 为具有近 30% 噪声的字母, 结果表明图中所示字母均可被正确识别. 图中 $(-1-i)$ 设为背景色, $(-1+i)$ 表示为 \bigcirc , $(1-i)$ 为 $\textcircled{\otimes}$, $(1+i)$ 为 \bullet .

我们也对四元数离散神经网络模型的 16 值灰度或彩色图象识别进行了计算机模拟应用. 如对图 5(a) 所示的 12×12 点阵图象的识别: 网络中存贮有四种不同灰度或颜色的图象. 若认为是彩色图象时, 各数值对应的颜色见表 1. 模拟表明, 这四种图象均为网络的稳定存贮图象. 而若输入一些其汉明距离达 60 (即噪声约 10%) 或距离为 110 (即噪声




图 4 复数模型用于四态字符识别的数值模拟实例
(a) 网络稳定存贮的三个字符 A; (b) 加有近 30% 噪声 (即 40 bit 误码) 的输入字符. 网络对 (b) 中所有图象均能正确识别

Fig. 4 The numerical simulation examples of the 4-state patterns recognition with the complex model

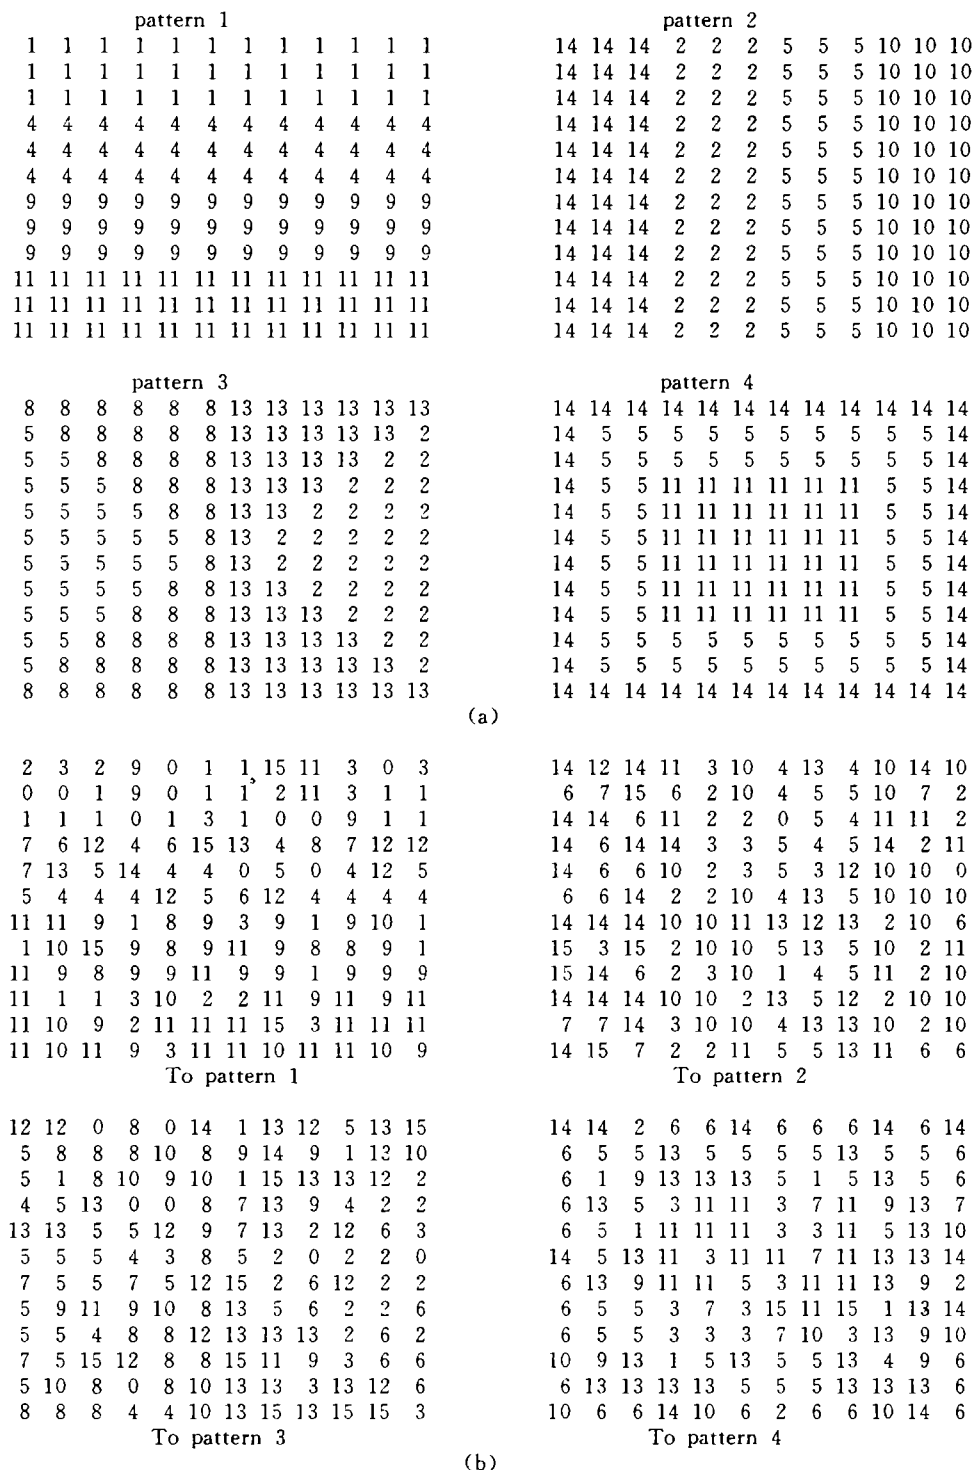


图5 四元数模型用于16态图象识别的数值模拟实例

(a) 网络稳定存贮的四个图象; (b) 加有近20%噪声的输入图象, 网络对(b)图象均能正确识别

Fig. 5 The numerical simulation examples of 16-state patterns recognition with thelton model

约20%)的变形图象,模型正确识别率分别约为95%和75%。图5(b)为加有近20%噪声的输入图象,结果表明图5(b)所示图象均可被正确识别。

在上节讨论的计算机数值模拟中,其样本是具有统计伪正交性的,而在本节实际图象识别中,由于其存贮图象间的正交性很差,且又因多元数间的交叉噪声的干扰,故对非正交样本的实际存贮图象数和联想纠错能力会较具有伪正交性样本的存贮图象数和联想纠错能力低。

3 器件实现讨论

神经网络的一个重要指标是模型器件实现的难易。从器件实现上来看,该模型要求各单元能处理 2^n 元数的运算,从而增加了神经元处理单元和突触连接处理单元的复杂性,而这也是所有多态神经网络所面临的问题,这是一个技术实现问题;另一个问题则从根本上决定了神经网络能否真正大规模实用化:随神经元数目的增加,高密度的空间连接限制问题。 2^n 元数模型模型由于用一个高维数表示一个象点的状态,每个神经元的连接总数为 $N-1$,与Hopfield模型相比,并未增加网络的空间连线密度,而是把复杂性转移到神经元处理单元和突触连接处理单元的技术实现上:要求各单元能处理 2^n 元数的基本运算。

由于集成电路的灵活性,对于双态值的模型的实现,原理上是可能的。而由光器件来兑现也是可能的,对于复数值的矢量和矩阵的乘法运算的光实现,已有不少的报导^[6~8]。如文[8]用光器件实现了128元素的8bit的复数值的矢量和矩阵的乘法运算,其主要原理是用两个实数来表示一个复矢量元素,而用一个实 2×2 矩阵表示一个复矩阵元素。这样,复数值的矢量和矩阵的乘法运算便转化为实数值的矢量和矩阵的乘法运算,而实数值的矢量和矩阵的维数是复数值的矢量和矩阵维数的两倍。实际上,我们可以把该思想推广到高维的 2^n 元数中,从而可用光器件来兑现 2^n 元数值的矢量和矩阵的乘法运算。

4 结 论

建立自动识别多值图象的人工神经网络,无论从应用还是从理论上来看,都是很具有重要意义的。我们把 2^n 元数引入神经网络中,用一个高维数表示一个象点的状态。神经网络模型从数的推广上,由实数,复数到四元数,八元数等, 2^n 神经网络模型能识别4, 16, 256值图象。

参 考 文 献

- 1 Rieger H. Storing an extensive number of grey-toned patterns in a neural network using multistate neurons. *J. Phys. A*, 1990, 23:L1 273~L1 279
- 2 Enten A C D v et al. Mean-field theory of random-site q-state Potts models. *J. Phys. A*, 1988, 21:791~801
- 3 Kanter I. Potts-glass models of neural networks. *Phys. Rev. A*, 1988, 37:2 739~2 742
- 4 Noest A J. Discrete-state phasor neural networks. *Phys. Rev. A*, 1988, 38:2 196~2 199
- 5 帅建伟等. 2^n 元神经网络模型:存贮容量分析. 厦门大学学报(自然科学版), 1995, 34(3):352~358
- 6 Goodman J W et al. Fully parallel, high-speed incoherent optical method for performing discrete Fourier transforms. *Opt. Lett.*, 1978, 2:1~3

- 7 Huang H X et al. Fast 11el complex discrete fourier transforms using a multichannel optical correlator. *Optics, Comm.*, 1988, 68:408~411
- 8 Mosca E P et al. Acoustooptical matrix-vector product processor: implementation issues. *Appl. Opt.*, 1989, 28:3 843~3 851

The 2^n -element Number Neural Networks Models: Application of the Multistate Patterns Recognition

Shuai Jianwei Chen Zhenxiang Liu Ruitang Wu Boxi
(*Dept. of Phys.*)

Abstract In this paper, the computer numerical simulation results show that the storage capacity and the error-correct ability of the 2^n -element number neural network models decrease with the increase of n . Some examples of the 4 or 16 states patterns recognition with $n=1$ or $n=2$ are discussed. Its optical implementation is simply discussed.

Key words Neural network, 2^n -element number, Pattern recognition